

参考如下

线性系统近似线性化

6_扩展卡尔曼滤波器_Extended Kalman Filter

扩展卡尔曼滤波（EKF）算法详细推导及仿真（Matlab）

一、概念：

(1) 扩展卡尔曼滤波算法

解决非线性状态估计问题最为直接的一种处理方法，尽管EKF不是最精确的“最优”滤波器，但在过去的几十年成功地应用到许多非线性系统中。所以在学习非线性滤波问题时应该先从EKF开始。EKF算法是将非线性函数进行泰勒展开，然后省略高阶项，保留展开项的一阶项，以此来实现非线性函数线性化，最后通过卡尔曼滤波算法近似计算系统的状态估计值和方差估计值。

(2) 数学上的线性化 (linearization)

是找函数在特定点的线性近似，也就是函数在该点的一阶泰勒级数。在动力系统研究中，线性化是分析非线性微分方程系统或是非线性离散系统，在特定平衡点局部稳定性的一种方法。

严格的讲，实际物理原件和系统都是非线性的。叠加原理不适应于非线性系统，这给求解非线性系统带来了不便，因此需要对所研究的系统做线性化处理。

线性化是某一点附近的线性化，不是全局的线性化。

泰勒级数展开是将一个在 $x = x_0$ 处具有n阶导数的函数 $f(x)$ ，利用关于 $(x - x_0)$ 的n次多项式逼近函数值的方法。

泰勒级数 (Taylor Series) ，若函数 $f(x)$ 在包含a的某个闭区间 $[b,c]$ 上具有n阶导数，且在开区间 (b,c) 上具有 $(n+1)$ 阶导数，则对闭区间 $[b,c]$ 上任意一点 x ，成立下式：在 $x=a$ 点处进行线性化：

$$f(x) = f(a) + \frac{f^{(1)}(a)}{1!}(x-a)^1 + \dots + \frac{f^{(n)}(a)}{n!}(x-a)^n$$

其中 $f^{(n)}(a)$ 表示 $f(x)$ 的n阶导数，等号后的多项式称为函数 $f(x)$ 在a处的泰勒展开式，剩余的 $R_n(x)$ 是泰勒公式的余项，是 $(x-a)^n$ 的高阶无穷小。

余项就是展开式与原函数的误差，余项越少，误差就越小。在一定允许的范围内，余项可以忽略不计，即所谓的无穷小。

泰勒公式的余项 $R_n(x)$ 可以写成以下几种不同的形式：

1、佩亚诺(Peano) 余项： $R_n(x) = o[(x - x_0)^n]$

这里只需要 n 阶导数存在

由于高阶无穷小，一般来说，EKF在对非线性函数做泰勒展开时，实际应用只取到一阶导，同样也能有较好的结果。取一阶导时，状态转移方程和观测方程就近似为线性方程，高斯分布的变量经过线性变换之后仍然是高斯分布，这样就能够沿用标准卡尔曼滤波的框架。

如果 $x-a$ 无限趋近于0， $(x - a)^2$ 就会无穷小，故第三项可以忽略不记，即：

$$f(x) = f(a) + \frac{f^{(1)}(a)}{1!}(x - a)^1$$

- 多变量系统的线性化：

假设：

$$\begin{cases} \dot{x} = f([x_1, x_2], u) \\ y = g([x_1, x_2], u) \end{cases}$$

知乎 @灵动方程

经过泰勒展开转化为线性系统后的状态空间表达式可以是：

$$\begin{cases} \dot{\hat{x}} = A\hat{x} + B\hat{u} \\ \hat{y} = C\hat{x} + D\hat{u} \end{cases}$$

二、EKF算法详细推导：

扩展卡尔曼滤波EKF的状态转移方程和观测方程为：

考虑高斯白噪声的非线性系统：

$$\begin{cases} x_{k+1} = f(x_k) + w_k \\ z_k = h(x_k) + v_k \end{cases}$$

x_k 为状态向量， z_k 量测向量， $f(\cdot)$ 和 $h(\cdot)$ 分别为系统非线性状态函数和量测函数
 w_k 和 v_k 分别是零均值，协方差为 Q_k 和 R_k 的不相关高斯白噪声。<https://blog.csdn.net/gangdanerya>

Nonlinear system

$$x_t = f(x_{t-1}, u_{t-1}, \omega_{t-1}), \omega_{t-1} \sim \mathcal{N}(0, Q)$$

$$z_t = h(x_t, v_t), v_t \sim \mathcal{N}(0, R)$$

f and h are both nonlinear function

Note

The nonlinear mapping of a Gaussian distribution is not Gaussian

正态分布的随机变量通过非线性系统后就不再是正态分布的了，所以w一定要用泰勒级数多变量展开。又因为是对u是控制量，是已知的不用展开

线性化：

选择初始点的最佳方法是最真实值。然而由于系统误差，我们没有这个。我们从后验估计中最后一个时间步长的 \bar{x}_{t-1} 线性化了系统

Taylor Series 泰勒级数：高维度用到雅可比矩阵

Taylor Series

$$f(x) = f(x_0) + \frac{\partial f}{\partial x}(x - x_0)$$

①预估

利用泰勒展开式对上式在上一次的估计值处 \bar{x}_{t-1} 展开得（多变量使用泰勒级数）

$$x_t = f(\hat{x}_{t-1}, u_{t-1}, \omega_{t-1}) + A_t(x_t - \hat{x}_{t-1}) + W_t\omega_{t-1}$$

Assuming $\omega_{t-1} = 0$, we get $\tilde{x}_t = f(\hat{x}_{t-1}, u_{t-1}, 0)$

$$A_t = \left(\frac{\partial f}{\partial x} \right)_{\hat{x}_{t-1}, u_{t-1}}$$

$$W_t = \left(\frac{\partial f}{\partial \omega} \right)_{\hat{x}_{t-1}, u_{t-1}}$$

假设我们已知 k 时刻状态估计值 $\hat{x}_{k|k}$ 和估计方差 $P_{k|k}$ ，
我们将非线性函数 $f(x_k)$ 在 $\hat{x}_{k|k}$ 处进行一阶泰勒展开可得：

$$f(x_k) = f(\hat{x}_{k|k}) + \frac{\partial f}{\partial x_k} \Big|_{x_k = \hat{x}_{k|k}} (x_k - \hat{x}_{k|k}) + o(x_k - \hat{x}_{k|k})$$

其中 $o(x_k - \hat{x}_{k|k})$ 为高阶项，我们定义 $\frac{\partial f}{\partial x_k} \Big|_{x_k = \hat{x}_{k|k}} = F_k$ ，忽略高阶项，状态方程 可以化简为：

$$x_{k+1} = f(\hat{x}_{k|k}) + F_k(x_k - \hat{x}_{k|k}) + w_k$$

$$\text{一步状态预测: } \hat{x}_{k+1|k} = E[f(\hat{x}_{k|k}) + F_k(x_k - \hat{x}_{k|k}) + w_k] = f(\hat{x}_{k|k})$$

$$\begin{aligned} \text{一步预测协方差: } P_{k+1|k} &= E[(x_{k+1} - \hat{x}_{k+1|k})(x_{k+1} - \hat{x}_{k+1|k})^T] \\ &= E\{[F_k(x_k - \hat{x}_{k|k}) + w_k][F_k(x_k - \hat{x}_{k|k}) + w_k]^T\} \\ &= F_k P_{k|k} F_k^T + Q_k \end{aligned}$$

<https://blog.csdn.net/gangdanerya>

②观测

$$\begin{aligned} z_t &= h(\tilde{x}, v_t) + H_t(x_t - \tilde{x}_t) + V_t v_t \\ &\text{Linearization at } \tilde{x}_t \\ &\text{Assuming } v_t = 0, \text{ we get } \tilde{z}_t = h(\tilde{x}_t, 0) \\ H_t &= \left(\frac{\partial h}{\partial x} \right)_{\tilde{x}_t} \\ V_t &= \left(\frac{\partial h}{\partial v} \right)_{\tilde{x}_t} \end{aligned}$$

$$\begin{aligned} \omega_t &\sim \mathcal{N}(0, Q) \\ W_t \omega_t &\sim \mathcal{N}(0, W_t Q W_t^T) \\ V_t v_t &\sim \mathcal{N}(0, V_t R V_t^T) \end{aligned}$$

预测

$$\hat{x}_t^- = F\hat{x}_{t-1} + Bu_{t-1}$$

$$P_t^- = FP_{t-1}F^T + Q$$

更新

$$K_t = P_t^- H^T (HP_t^- H^T + R)^{-1}$$

$$\hat{x}_t = \hat{x}_t^- + K_t(z_t - H\hat{x}_t^-)$$

$$P_t = (I - K_t H)P_t^-$$

↓

Summary

propagation		correction	
prior	$\hat{x}_t^- = f(\hat{x}_{t-1} + u_{t-1}, 0)$	Kalman gain	$K_t = (P_t^- H^T)(HP_t^- H^T + V_{t-1}RV_{t-1}^T)^{-1}$
prior error covariance	$P_t^- = AP_{t-1}A^T + W_{t-1}QW_{t-1}^T$	posterior estimation	$\hat{x}_t = \hat{x}_t^- + K_t(z_t - h(\hat{x}_t^-))$
		update error covariance	$P_t = (I - K_t H)P_t^-$

三、EKF的不足

运动及观察模型用泰勒级数的一阶展开近似成线性模型，忽略了高阶项，不可避免的引入线性误差，甚至导致滤波器发散。有如下误差补偿方法：

泰勒近似使得状态预测必然存在误差：

1补偿状态预测中的误差，附加“人为过程噪声”，即通过增大过程噪声协方差来实现这一点。 2扩大状态预测协方差矩阵，用标量加权因子 $\varphi > 1$ 乘状态预测协方差矩阵 3利用对角矩阵 $\varphi = \text{diag}(\text{sqrt}(\varphi_i))$, $\varphi_i > 1$ 来乘以状态预测协方差矩阵

其实无论增大过程噪声协方差还是状态预测协方差矩阵，都是为了增大kalman增益，即状态预测是不准的，我要减小一步状态预测在状态更新中的权重。

雅克比矩阵（一阶）及海塞矩阵（二阶）计算困难。二阶EKF的性能要好于一阶的，而二阶以上的性能相比于二阶并没有太大的提高，所以超过二阶以上的EKF一般不采用。但二阶EKF的性能虽好，但计算量大，一般情况下不用